

Национальный исследовательский университет «Высшая школа экономики»

Факультет "Экономика и анализ данных"

Литературный обзор:  
Скоринговая модель как инструмент  
эффективной оценки кредитоспособности

Студент:	Миннеахметова Рената
Преподаватель:	Рамазян Тигран
Группа:	БЭАД 221

Москва  
2023

## Содержание

1	Введение	2
2	Статья №1	2
3	Статья №2	3
4	Статья №3	4
5	Статья №4	5
6	Статья №5	6
7	Статья №6	7
8	Статья №7	7
9	Статья №8	8
10	Статья №9	8
11	Статья №10	9
12	Статья №11	9
13	Статья №12	10
14	Заключение	10

# 1 Введение

В данном литературном обзоре я буду рецензировать 12 статей на тему "Скоринговая модель как инструмент эффективной оценки кредитоспособности". Здесь будет представлена оценка содержания приведенных научных статей, описание допущений, сделанных в исследованиях и вычислениях и критическое сравнение полученных в них результатов.

## 2 Статья №1

Глинкина Е.В. (2011). Кредитный скоринг как инструмент эффективной оценки кредитоспособности. Финансы и кредит, (16 (448)), 43-47.

В данной статье описывается концепция кредитного скоринга, который широко используется в банковской сфере для оценки кредитоспособности заемщиков. Автор рассматривает его общий алгоритм, подчеркивает эффективность скорингового подхода, который начал применяться не только в потребительском кредитовании, но и для оценки финансового состояния юридических лиц. Оцениваются основные компоненты скоринговых моделей в США, в ЕС, в Великобритании и Германии. Автор также указывает наиболее часто применимые методы оценки, такие как расчет финансовых коэффициентов, экспертный анализ и статистические методы.

В данной работе рассматривается разнообразие видов кредитного скоринга в международной банковской практике, включая application scoring, behavioral scoring, collection scoring и fraud scoring. Отмечается, что в российской банковской среде такой градации нет.

Текст также подчеркивает специфику российских моделей скоринговой оценки заемщика, основанных на методологических рекомендациях Банка России. Однако отмечается неоднозначность в классификации и отсутствие четких критериев для оценки финансового состояния заемщика, что дает банкам широкий простор для интерпретации и формирования резервов.

Автор указывает на необходимость разработки собственных скоринговых моделей банками из-за отсутствия четкой регламентации. Российские банки вынуждены адаптировать западные модели, но при этом учитывать российскую специфику, такую как отсутствие надежной статистической информации, искажение данных финансовой отчетности, закрытость компаний и отсутствие кредитной культуры.

В последней части статьи подробно повествуется о субъективности многих оценок скоринговой модели, из-за чего возникает погрешность, и важности использования финансовых составляющих. Указывается ключевая проблема банковской сферы РФ - инсайдерское кредитование. А также делается акцент на роли актуальности данных, которые используются в построении скоринговой модели.

Теперь перейдем к рецензии. Цель статьи - познакомить читателя с таким методом оценки кредитоспособности заемщика как скоринг. То есть в данной статье раскрывается в основном теоретический смысл и разновидности существующих подходов. Однако сам процесс оценки остается не ясен. Общий алгоритм не раскрывает, как именно считать те или иные показатели.

Далее в параграфе про основные составляющие зарубежных моделей автор пишет: "Каждый из данных компонентов (характеристик) включает исследование отдельного аспекта деятельности субъекта и оценивается по определенной шкале – как правило, пятибалльной". Возникает вопрос, какая оценка от 1 до 5 какому состоянию соответствует.

Предоставлена исчерпывающая информация о разновидностях кредитного скоринга в международной банковской сфере и необходимости индивидуального подхода к разработке модели в России в силу характерных особенностей нашего государства.

Также хочу отметить, что данная статья написана в 2011 году. Возможно в силу этого не указан подход с применением современных технологий таких, как, например, построение модели с помощью машинного обучения. Из-за этого актуальность статьи несколько теряется.

### 3 Статья №2

Alireza Hooman, Govindan Marthandan, Wan Fadzilah Wan Yusoff, Mohana Omid and Sasan Karamizadeh (2016). STATISTICAL AND DATA MINING METHODS IN CREDIT SCORING, The Journal of Developing Areas, Vol. 50, No. 5, Special Issue on the Kuala Lumpur COnference, November 23-24, 2015 (2016), pp. 371-381

Как следует из названия, в этой статье рассказывается о различных статистических методах кредитного скоринга, а также дата-майнинг. Во вступлении кратко рассказывается о том, что такое кредитный скоринг, на каких параметрах он основывается и почему именно статистические методы важны.

Авторы пишут о том, что процентных ставок недостаточно для того, чтобы точно предсказать все риски выдачи кредита. Ручной анализ данных сильно усложняет выявление правильного ответа, нужно ли конкретному заемщику выдавать кредит или нет. Именно дата-майнинг помогает ускорить и автоматизировать процесс.

В статье указывается, что целью данного исследования является обзор литературы по системам дата-майнинга, которые использовались для оценки кредитного риска в период с 2000 по 2015 год. Эта статья повысит осведомленность читателей относительно существующих методов, их основных целей и соответствующих ограничений, что приведет к предложению более эффективных методов.

Предоставляется информация о классификации рассматриваемых методов. Дата-майнинг делится на две категории: обучение с учителем и обучение без учителя. Первая категория включает в себя такие методы, как кластеризация, суммаризация, обучение ассоциативным правилам, секвенциальный анализ. Обучение без учителя - это регрессия, временные ряды, дискриминация (eng. discrimination). При этом под категорию кредитного скоринга из первой группы попадает только кластеризация, а из второй все три указанных метода.

Далее авторы подробнее рассказывают о каждом методе, приводят плюсы и минусы использования. Дискриминантный анализ используется для классификации наблюдений на два различных класса. Плюсы дискриминантного анализа: наиболее эффективная техника для целей кредитного скоринга; легкость в реализации и интерпретации; наиболее эффективная техника при применении к большой выборке. Минусы: необходимость статистических предположений; необходимость упорядоченных категориальных переменных; чувствительность к выбросам.

Логистическая регрессия способна прогнозировать различный результат группы переменных, которые могут быть двоичными, дискретными, непрерывными или их комбинацией. В общем случае зависимая переменная обычно является двоичной. Преимущества этого метода заключаются в том, что логистическая регрессия не предполагает линейной связи между зависимыми и независимыми переменными; она не требует, чтобы набор переменных имел нормальное распределение. Основным преимуществом этого метода является возможность создания простой вероятностной формулы для классификации. Недостатки заключаются в том, что логистическая регрессия не

способна эффективно справляться с проблемами нелинейных и кооперативных эффектов объясняющих переменных.

Пробит-регрессия - это N-уровневая архитектура, интегрированная с Model View Controller, которая моделирует скоринг в соответствии с изменениями в бизнесе. Одним из преимуществ этого дизайна является то, что требуется меньше времени для внесения изменений в модели скоринга. Кроме того, модели могут быть настроены по требованию менеджеров. В тексте перечислены несколько преимуществ пробит-регрессии: меньше времени затрачивается на внедрение; легко изменять модели в любое время.

Еще множество других подходов в кредитном скоринге перечислили авторы. Что касается рецензии данной статьи, то хочется сказать, что в отличие от предыдущей статьи данная раскрывает именно дата-майнинг и построение скоринговых моделей. Обычному читателю, не погруженному в computer science будет довольно сложно понять, как именно каждый метод работает. То есть авторы предоставляют лишь краткое неисчерпывающее описание, а затем перечисляют плюсы и минусы. Также не раскрывается, как именно были выведены плюсы и минусы, то есть проводились ли опросы или же это мнение авторов. Очевидное достоинство данной статьи заключается в ее актуальности. Список литературы состоит из источников, опубликованных не раньше 2003 года. В основном же даты публикации 2010-2015 гг. Также хочу добавить, что в статье присутствует несколько схем для больше наглядности, что делает прочтение и понимание материала более простым и удобным.

## 4 Статья №3

Самойлова, С. С., Курочка, М. А. (2014). Скоринговые модели оценки кредитного риска. Социально-экономические явления и процессы, 9 (3), 99-102.

В данной статье раскрывается повышение важности кредитного скоринга в России, раскрывается суть скоринга. Также автор перечисляет безусловные преимущества такого подхода: ускорение процесса выдачи или невыдачи кредитов, нивелирования человеческого фактора при принятии решения, предотвращение мошенничества. И недостатки: недостаточность имеющихся данных, на основе которых должен работать скоринг, не соответствие предоставленных заемщиком данных о себе с действительностью.

Далее автор перечисляет существующие типы кредитного скоринга на международной арене и говорит о том, что не все эти типы доступны в России, поскольку скоринг в нашем государстве начал развиваться не так давно.

Важной составляющей представленной статьи является таблица сравнения типового подхода к оценке заемщика и системы кредитного скоринга. Сравнение осуществляется по таким критериям, как "первичная обработка кредитной заявки"[1] (у первого подхода она основывается на знаниях кредитного эксперта; у второго же она построена на объективной доступной информации), "процесс оценки идентичных заявок"[1] - аналогично, как и первый критерий, говорит нам о том, что система кредитного скоринга имеет более объективный подход, не зависящий от человеческого фактора; "легкость восприятия"[1] - не совсем понятный пункт, заключающийся в том, что сотрудники не готовы применять современные методы анализа данных; "процесс внедрения"[1] - несколько противоречивый, на мой взгляд, критерий - авторы утверждают, что типовой подход требует большего количества времени обучения специалистов, нежели скоринг, но я бы хотела с этим не согласиться, поскольку современные методы построения скоринговой модели требуют глубоких знаний математической статистики, линейной алгебры и языков программирования;

"возможность ошибок, злоупотреблений и мошенничества" [1] - авторы указывают читателю на то, что процент мошенничества при типовом подходе - с одной стороны, это логично, но хотелось бы увидеть реальную статистику, подтверждающую данные слова; "гибкость" [1] - рассмотрен пример внедрения нового продукта, в тексте говорится о том, что скоринговые модели могут быть протестированы без запуска в работу, в отличие от обычного подхода к оценке кредитоспособности заемщика.

Помимо преимуществ, недостатков и вопросов к содержанию статьи в предыдущем параграфе, хочется также упомянуть недостаточность реальных данных в доказательствах той или иной точки зрения, то есть непонятно, насколько редко в России используются скоринговые модели, насколько чаще компании выбирают стандартные типовые подходы. На мой взгляд, такой статистики не хватает для более объективного сравнения двух разных подходов.

## 5 Статья №4

Jin Xiao, Ling Xie, Dunhu Liu, Yi Xiao and Yi Hu (2016). A Clustering and Selection Based Transfer Ensemble Model for Customer Credit Scoring, *Filomat*, Vol. 30, No. 15, *Quantitative Economics and Its Development*, pp. 4015-4026

В данной статье авторы говорят о том, что проблематично достичь удовлетворительных результатов в кредитной банковской сфере с использованием традиционных моделей, построенных на предположении, что обучающие и тестовые данные подчиняются одному и тому же распределению, поскольку клиенты обычно происходят из различных регионов и могут подвергаться различным распределениям в реальности. В данном исследовании используется ансамблевое обучение с передающим обучением и предложена модель передающего ансамбля на основе кластеризации и выбора (CSTS) для передачи экземпляров из связанных исходных доменов в целевой домен для помощи в моделировании. Результаты экспериментов на двух наборах данных по оценке кредитоспособности клиентов показывают, что модель CSTS превосходит две традиционные модели оценки кредитоспособности, а также три существующих модели передающего обучения.

Авторы оперируют данными из Bank of England и The Federal Reserve Board, говоря о том, что объем невыплаченных потребительских кредитов (за исключением ипотечных кредитов) в США и Великобритании к концу 2009 года составил соответственно 2,5 трлн долларов и 171 млрд фунтов. В то же время годовые уровни списаний по кредитным картам и потребительским кредитам в США и Великобритании составляли 5,4% [2] и 1,5% [3] соответственно. Это явно указывает на множество ошибок в банковских структурах выдачи кредитов и определения кредитоспособности заемщиков и необходимости введения новых методов.

Теперь я бы хотела разобрать допущения в описанном в статье подходе кластеризации. Авторы пишут, что модель CSTE направлена на передачу полезной информации из связанных исходных доменов для помощи в моделировании целевого домена. В реальных задачах оценки кредитоспособности исходные домены обычно содержат много шумов. Таким образом, если образцы заявителей переданы из исходного домена в целевой домен без разбора или неправильно, это может привести к негативному эффекту передачи из-за введения слишком многих шумов [4]. Поэтому необходимо рассмотреть, как избежать негативной передачи при построении модели передающего обучения.

Авторы предложили модель передающего ансамбля на основе выбора признаков, предполагая, что существует только один исходный домен, связанный с целевым доменом. Однако в реальных задачах оценки кредитоспособности клиентов может быть много исходных доменов, и как

построить модель передающего ансамбля в этом случае - как раз и задача данного исследования. Авторы предполагают, что  $T$  - это набор данных целевого домена задачи по оценке кредитоспособности, и есть  $p$  наборов данных исходных доменов  $S(i=1, 2, \dots, p)$ , связанных с  $T$ . В то же время и  $T$ , и  $S$  содержат два типа образцов: образцы плохой кредитной истории с меткой класса 1 и образцы хорошей кредитной истории с меткой класса 2. Далее, целевой домен  $T$  разделяется на два подмножества: целевой обучающий набор  $T1$  и целевой тестовый набор  $T2$ . Чтобы эффективно избежать негативной передачи, модель CSTE, предложенная в данном исследовании, содержит 3 фазы: 1) Передача наборов данных исходных доменов с выбором. Сначала она использует алгоритм  $k$ -средних для разделения  $T1$  на  $k$  кластеров и получает начальную программу кластеризации  $CI$ . В этом исследовании предполагается, что класс метки набора данных содержит только два класса: хороший и плохой кредит, поэтому мы устанавливаем  $k=2$ . Далее она объединяет каждый набор данных исходного домена  $S(i=1, 2, \dots, p)$  с  $T1$  и снова проводит кластеризацию с помощью алгоритма  $k$ -средних (число кластеров по-прежнему 2), чтобы получить новую программу кластеризации  $C(i=1, 2, \dots, p)$ . Наконец, вычисляется согласованность между  $C$  и начальной программой кластеризации  $CI$ , после чего передаются половина исходных доменов с более высокой согласованностью в целевой обучающий набор для формирования нового обучающего набора  $TR$ ; 2) Устранение шумовых данных в новом обучающем наборе. Сначала, как и в Фазе 1, новый обучающий набор  $TR$  кластеризуется на 2 кластера с использованием алгоритма  $k$ -средних. Если образцы принадлежат двум классам в одном кластере, то этот кластер разбивается дополнительно. Тем временем исключается изолированный кластер с меньшим количеством образцов. В конце концов нумеруются все кластеры и рассматриваются как метки классов образцов в конечном обучающем наборе  $Tf$ ; 3) Обучение базовых классификаторов и классификация целевого тестового набора  $T2$ . Сначала случайным образом с заменой выбираются  $N$  обучающих поднаборов из  $Tf$ . В этот момент распределение классов обучающих поднаборов и затем балансируется каждый поднабор с использованием технологии оверсэмплинга. Затем обучается классификатор в каждом сбалансированном поднаборе и классифицируется  $T2$  с каждым классификатором. В конце концов получаются окончательные результаты ансамблевой классификации с использованием взвешенного голосования.

Во-первых стоит упомянуть ограничение на использование двух классов: исследование предполагает, что класс метки набора данных содержит только два класса (хороший и плохой кредит). Но в реальных сценариях кредитоспособности могут существовать более сложные классы, и использование только двух классов может упрощать задачу.

Во-вторых, из статьи неясно, как исходные данные должны обрабатываться. То есть реальные наборы данных могут содержать сложные и неучтенные влияния.

## 6 Статья №5

Сорокин, А. С. (2014). Построение скоринговых карт с использованием модели логистической регрессии. Вестник евразийской науки, (2 (21)), 82.

Данная статья содержит информацию о том, как можно применять модели логистической регрессии для построения скоринговых карт. Я хотела бы сначала разобрать второй пункт данной статьи - "Подготовка данных для построения скоринговой модели". В тексте говорится о том, что исходные "данные должны удовлетворять требованиям статистической значимости и случайности"[5]. Однако, не дается конкретных примеров или методов для проверки этой случайности и значимости данных. Дополнительные пояснения или примеры могли бы уточнить этот

аспект.

Также автор упоминает использование внешних данных кредитных историй, но не раскрывает, каким образом эти данные интегрируются, как они проверяются на достоверность, и как они могут влиять на точность модели.

Помимо вышеперечисленного, утверждается, что "использование нескольких скоринговых карт <...> может обеспечивать лучшее дифференцирование риска"[5]. Однако, не предоставляются конкретные примеры сценариев, когда такой подход может быть наиболее эффективным, и не указываются критерии выбора между одной или несколькими картами.

Еще я бы хотела упомянуть корректность всех произведенных в этой статье вычислений и применение логистической регрессии. Однако выбранный датасет весьма ограничен для наглядности, что с одной стороны является плюсом, а с другой минусом. Читатель не может сделать вывод о погрешностях и правильности выполнения всех алгоритмов для больших данных.

## 7 Статья №6

Шунина Ю.С., Алексеева В.А., Клячкин В.Н. (2015). Прогнозирование кредитоспособности клиентов на основе методов машинного обучения. Финансы и кредит, (27 (651)), 2-12.

Данная статья раскрывает основные методы машинного обучения для кредитного скоринга - прогнозирования кредитоспособности заемщиков. Автор показывает, как считаются параметры с помощью дискриминантного анализа, логистической регрессии, метода нейронных сетей, деревьев принятия решений, метода опорных векторов, наивный байесовский классификатор.

Хочу отметить, что статья как полностью раскрывает содержание каждого метода, то есть его смысл, преимущества и недостатки, так и показывает, как он применяется на практике, по каким формулам работает. Более того, для каждого метода найдены значения среднеквадратичной ошибки прогнозирования. Выявлена лучшая комбинация моделей для анализа кредитного рынка. Выбрана контрольная выборка и посчитана точность верно классифицированных клиентов.

Одним из весомых преимуществ данной статьи является выбранный реальный датасет для построения всех моделей и исследования - данные по немецким заемщикам [6], как утверждает автор. Однако предоставленная ссылка недействительна (как с VPN, так и без).

## 8 Статья №7

Řezáč, M., Řezáč, F. (2011). How to measure the quality of credit scoring models. Finance a úvěr: Czech Journal of Economics and Finance, 61(5), 486-507.

Авторы этой работы подходят к кредитному скорингу несколько с другой точки зрения, нежели в предшествующих статьях. Они хотят исследовать, как можно определить качество уже построенной модели. Утверждается, что можно использовать количественные индексы, такие как индекс Джини, статистика K-S, Лифт, махаланобисовское расстояние и информационная статистика. Эти показатели применяются для сравнения нескольких разработанных моделей как на момент разработки, так и для мониторинга качества этих моделей после внедрения в реальный бизнес. В тексте говорится о том, что на практике наиболее широко используются индексы Джини,



лидирующий в Европе, и КС, лидирующий в Северной Америке. Несмотря на то, что их использование может быть не оптимальным. Очевидно, что нам необходимо иметь наилучшую производительность заданной модели скоринга около ожидаемого порогового значения. Следовательно, мы должны оценивать индексы качества с этой точки зрения. Индекс Джини является глобальной мерой, поэтому невозможно использовать его для оценки локального качества. КС идеален, если ожидаемое пороговое значение близко к тому месту, где реализуется КС

Авторы дают точные определения вводимым ими терминам, дают точные формулы вычисления той или иной характеристики для полной объективности. А также предоставляют графики для всех рассматриваемых ими случаев. В процессе рассматривания всевозможных критериев авторы делают выводы, основываясь на свои точные вычисления, что может свидетельствовать о том, что существуют исключения, не учтенные авторами.

## 9 Статья №8

HUSSEIN A. ABDON AND JOHN POINTON (2011). CREDIT SCORING, STATISTICAL TECHNIQUES AND EVALUATION CRITERIA: A REVIEW OF THE LITERATURE. *Intell. Sys. Acc. Fin. Mgmt.* 18, 59–88

В этой статье разбираются 214 статьи [7] на тему кредитного скоринга. Авторы начинают с первых упоминаний этого термина, затем рассматривают множество определений, встречающихся в различных источниках. А затем сравнивают методы оценки кредитоспособности заемщика с помощью скоринга. Более того, сравнение различных статистических подходов показывает, что более сложные и современные методы, такие как нейронные сети и генетическое программирование, работают лучше, чем более традиционные методы, такие как дискриминантный анализ и логистическая регрессия, в терминах их более высокой предсказательной способности. Однако результаты некоторых исследований показали, что предсказательные возможности обоих подходов достаточно схожи, что затрудняет их различение.

Из этого обзора литературы следует вывод, что не существует универсального лучшего статистического метода, используемого для построения моделей кредитного скоринга. Его невозможно выявить.

Эта статья имеет важный плюс, поскольку ее авторы не предвзято подходят к различным точкам зрения.

## 10 Статья №9

Никаненкова, В. В. (2012). Кредитный скоринг как инструмент оценки кредитоспособности заемщиков. *Вестник Адыгейского государственного университета. Серия 5: Экономика*, (2), 32-38.

Авторы данной статьи погружают читателя в возникновение и историческое развитие кредитного скоринга. "Первое упоминание о скоринге уходит в 1936 год, когда Хансом Фишером (1881–1945) была предложена классификация популяции растений на группы. Дэвид Дюран в своем исследовании *Risk Elements in Consumer Installment Financing* переложил данную методику при классификации кредитов на «плохие» и «хорошие», что было связано с недостатком квалифицированных кредитных аналитиков в период Второй мировой войны. Методика Дюрана состояла в

следующем: он выделил группы факторов и их весовые значения, позволяющие определить степень кредитного риска, и установил границу выдачи ссуды как 1,25 и более. Факторы, выделенные Дюраном, и баллы, присваиваемые заемщикам в зависимости от конкретных значений этих факторов, были следующими [8]): 1. Возраст: 0,1 балл за каждый год свыше 20 лет (максимум – 0,30). 2. Пол: женский (0,40), мужской (0). 3. Срок проживания в регионе: 0,042 за каждый год (максимально – 0,42). 4. Профессия: 0,55 за профессию с низким риском, 0 за профессию с высоким риском, 0,16 – другие профессии. 5. Работа: 0,21 на предприятиях общественной отрасли, 0 – другие. 6. Срок занятости: 0,059 за каждый год работы на данном предприятии. 7. Финансовые показатели: 0,45 за наличие банковского счета, 0,35 за наличие недвижимости, 0,19 – за наличие полиса по страхованию." [9]

Также авторы предоставляют таблицы точности различных методов классификации без указания на то, как конкретные значения были посчитаны.

Итог этой работы - выделение преимуществ кредитного скоринга. Однако не совсем понятно, как многие выводы были сделаны, ведь никаких рассуждений, предшествующих им не было.

## 11 Статья №10

Markov, A., Seleznyova, Z., Lapshin, V. (2022). Credit scoring methods: Latest trends and points to consider. The Journal of Finance and Data Science.

Эта статья направлена на предоставление системного обзора наиболее актуальных (2016–2021) статей, выявление тенденций в кредитном скоринге с использованием фиксированного набора вопросов. Методология и опросник опроса соответствуют предыдущему подобному исследованию, анализирующему статьи по кредитному скорингу, опубликованные в 1991–2015 годах. Авторы стремятся сравнить наши результаты с предыдущими периодами и выделить некоторые из последних лучших практик в этой области, которые могут быть полезны для будущих исследователей.

Авторы полностью обосновывают свой выбор рассматриваемых ими статей. Описывают алгоритм своих действий в ходе этой работы. Авторы акцентируют внимание читателя на том, что "в связи со спецификой моделирования кредитного риска собранная информация по статьям может быть объединена в пять основных кластеров:

- 1) Метаданные. Название, авторы, журнал, год публикации.
- 2) Информация о наборе данных. Количество наборов данных, типы наборов данных, использование популярных наборов данных.
- 3) Архитектура модели. Техники подготовки данных и выбора переменных.
- 4) Тестирование модели. Метод валидации.
- 5) Результаты производительности модели. Критерии стоимости, используемые модели в литературе, список лучших и наихудших моделей." [10]

Далее проводится полный обзор на источники с визуализацией результатов для наглядности. Также объяснены, откуда и как получаются те или иные результаты. Используются реальные датасеты с сайта kaggle [11]. С математической точки зрения все исчерпывающе объяснено.

## 12 Статья №11

Wei, Y., Yildirim, P., Van den Bulte, C., Dellarocas, C. (2016). Credit scoring with social network data. Marketing Science, 35(2), 234-258.

Не совсем ожидаемая, но злободневная статья про связь кредитного скоринга и социальных сетей. В этой статье сравнивается подход кредитования с использованием данных о заемщиках из социальных сетей и без. Эта статья мне показалась не совсем понятной, поскольку использовалось множество субъективных факторов, пытаюсь преобразовать их в математические значения. Однако аргументы, почему это будет верное решение, авторы не предоставляют. Интересное видение будущего кредитного скоринга, но не совсем обоснованное. Также для среднего читателя будет не ясно математическое содержание статьи, поскольку не везде объясняется, что откуда берется и почему именно такое математическое действие совершается

## 13 Статья №12

Kiviat, B. (2019). Credit scoring in the United States. *economic sociology the european electronic newsletter*, 21(1), 33-42.

Эта статья интересна тем, что показывает примеры, как кредитный скоринг в США существует повсюду. "В современных США кажется, что кредитные рейтинги повсюду. Fair Isaac рекламирует во время национального чемпионата по футболу, напоминая людям проверить свои кредитные рейтинги на MyFico.com (Poop 2012). Выписки из банков и кредитные счета поступают с выделенными вверху рейтингами. Даже The New York Times сообщает, что люди спрашивают о кредитных рейтингах на свиданиях (Silver-Greenberg 2012). Практика и идея кредитного скоринга продолжают расширять свое влияние на жизнь американцев." [12]

Статья наполнена актуальными примерами из жизни американцев, цитатами из интервью генеральных директоров банков, нестандартно, но верно используемыми статистическими данными

## 14 Заключение

В заключение хочу сказать, что все выбранные мною статьи с разных сторон раскрывают тему "Скоринговая модель как инструмент эффективной оценки кредитоспособности". Цель данного литературного обзора выяснить недостатки и преимущества того или иного подхода.

## Список литературы

- [1] Глинкина, Е.В. (2011). Кредитный скоринг как инструмент эффективной оценки кредитоспособности. Финансы и кредит, (16 (448)), 43-47.
- [2] England, B. O. Trends in Lending June 2010. Bank of England, 2010.
- [3] Board, TFR. Federal Reserve Statistical Release G.19. The Federal Reserve Board, 2010.
- [4] Rosenstein, M. T., Marx, Z., Kaelbling, L. P. To transfer or not to transfer, In: NIPS 2005 Workshop on Transfer Learning.
- [5] Сорокин, А. С. (2014). Построение скоринговых карт с использованием модели логистической регрессии. Вестник евразийской науки, (2 (21)), 82.
- [6] URL: [http://www.stat.uni-muenchen.de/service/datenarchiv/kredit/kredit\\_e.html](http://www.stat.uni-muenchen.de/service/datenarchiv/kredit/kredit_e.html)
- [7] URL: <https://onlinelibrary.wiley.com/doi/epdf/10.1002/isaf.325>
- [8] Churchill G.A., Nevin J.R., Watson R.R. The role of credit scoring in the loan decision // Credit World. 1977. March.
- [9] Никаненкова, В. В. (2012). Кредитный скоринг как инструмент оценки кредитоспособности заемщиков. Вестник Адыгейского государственного университета. Серия 5: Экономика, (2), 32-38.
- [10] Markov, A., Seleznyova, Z., Lapshin, V. (2022). Credit scoring methods: Latest trends and points to consider. The Journal of Finance and Data Science.
- [11] URL: <https://www.kaggle.com>
- [12] Kiviat, B. (2019). Credit scoring in the United States. economic sociology the european electronic newsletter, 21(1), 33-42.